

Программирование на Python для бизнес-аналитики

Магистратура «Бизнес-аналитика и цифровые решения в финансах» · ВШБ НИУ ВШЭ

Факторный анализ и визуальное представление результата

Дмитрий Тихомиров · 3 октября 2026

Что такое факторный анализ

Показатель изменился — **за счёт чего?** Факторный анализ раскладывает изменение на части.

Наблюдение

«Выручка упала на 1,6 млн ₽».

Ответ аналитика

«1,5 млн из них — отмены
подписок одного канала.
Остальное — шум».


- **Фактор** — то, из чего показатель складывается или на что умножается: канал, число платежей, цена.
- **Влияние фактора** — на сколько рублей показатель изменился из-за него.
- Сумма влияний всех факторов равна изменению показателя — до копейки.

Модель	Формула	На какой вопрос отвечает
Аддитивная	$R = R_1 + R_2 + \dots$	где изменилось: в каком канале или тарифе
Мультипликативная	$R = N \times P$	что изменилось: количество или цена

График демо с первой лекции. В нём три ошибки

Крайние столбики — выручка двух недель, между ними — изменения каналов.

Из чего сложилось изменение выручки · неделя с 24.08.2026



Найдите хотя бы одну. Подсказка: две ошибки — из Л4 и Л5, третья — тема сегодняшней пары.

Тот же код демо, что на Л1, — на нынешних данных курса.

Три ошибки — и где мы их проходили

Ошибка	Как её увидеть	Откуда
Каналы не сходятся с итогом	Изменения шести каналов в сумме дают -2,56 млн ₽, а итоги различаются на -2,60 млн: пропали 45 тыс. ₽ клиентов без канала	Л4: <code>dropna=False</code>
Неделя неполная	30 августа выгружено наполовину: 0,92 млн ₽ против 1,79 млн накануне. Около 0,9 млн «падения» не было	Л5: равные окна
Ось начинается не с нуля	Ось идёт от 10,04 млн: итоговые столбики различаются по высоте в 2,5 раза, а выручки — в 1,2 раза	сегодня

Демо Л1: недели 17–23.08 и 24–30.08; код демо — `charts.py`, `metrics.py`:69. Прогон 02.10.

Аддитивная модель: показатель — сумма частей

$$R = R_1 + R_2 + \dots + R_k$$

$$\Delta R = \Delta R_1 + \Delta R_2 + \dots + \Delta R_k$$

Выручка — сумма выручек каналов. Значит, её изменение — сумма изменений каналов.

Две кофейни, выручка за день, тыс. ₽

	Было	Стало	Изменение
На Мясницкой	300	240	-60
На Покровке	200	210	+10
Сеть	500	450	-50

Кофейни — выдуманный пример.

- $-60 + 10 = -50$: всё падение сети дала одна кофейня, вторая даже выросла.
- Влияние части на итог — это её собственное изменение. Модель отвечает на вопрос **«где»**.
- Подходит, когда части складываются в целое: каналы, тарифы, регионы, продукты.
- Не подходит для средних и долей: средний чек сети не равен сумме средних чеков кофеен.

Аддитивная модель на ПРАЙМ: 93 % падения — один канал

```
r = win.pivot_table(index="channel", columns="w",
                    values="r", aggfunc="sum")
t = pd.DataFrame({"r0": r["w0"], "r1": r["w1"]})
t["delta"] = t["r1"] - t["r0"]
t = t.sort_values("delta")
print(t.round().astype(int))
total = t["r1"].sum() - t["r0"].sum()
assert abs(t["delta"].sum() - total) < 0.01
```

	r0	r1	delta
channel			
partner_telecom	2083772	587792	-1495980
organic	3637058	3584899	-52159
social	1442495	1411660	-30835
без канала	243101	218581	-24520
crm	1604468	1580785	-23683
referral	1107935	1094285	-13650
performance	2314541	2340478	25937

win — из базы: канал, окно w (17–22.08 и 24–29.08), выручка r, число платежей n. Прогон 03.10.

- pivot_table ставит окна в колонки. delta — изменение канала, оно же его влияние.
- partner_telecom дал **93 %** падения: -1,50 из -1,61 млн ₽.
- Пять каналов изменились не больше чем на 2 %, «без канала» — на 10 %: среди полуночных отмен были и его подписки.
- assert молчит — значит, сумма влияний равна изменению итога.

Мультипликативная модель: произведение факторов

$$R = N \times P$$

выручка = платежи × средний чек

Аддитивная модель сказала **где** — в partner_telecom. Мультипликативная говорит, **что** изменилось: количество или цена.

Другие произведения в подписке

- выручка = подписки × ARPU
- подписки = регистрации × конверсия

Разные ответы — разные решения

Что изменилось	Куда смотреть
Платежей меньше, чек тот же	ушли подписки: удержание, партнёр, сбой списаний
Платежей столько же, чек меньше	скидки, переход на дешёвый тариф: цены и тарифы

Сколько рублей изменения дал каждый фактор, считает метод цепных подстановок.

Выручка = число платежей × средний чек

```
n = win.pivot_table(index="channel", columns="w",
                    values="n", aggfunc="sum")
m = pd.DataFrame({"n0": n["w0"], "n1": n["w1"],
                  "p0": r["w0"] / n["w0"],
                  "p1": r["w1"] / n["w1"]})
m = m.loc[t.index]
print(m.round(2))
```


	n0	n1	p0	p1
channel				
partner_telecom	6428	1808	324.17	325.11
organic	11242	11051	323.52	324.40
social	4455	4340	323.79	325.27
без канала	749	669	324.57	326.73
crm	4932	4865	325.32	324.93
referral	3415	3365	324.43	325.20
performance	7109	7222	325.58	324.08

win, r и t — со слайда аддитивной модели. Окна 17–22.08 и 24–29.08: понедельник–суббота, сутки UTC, успешные платежи. Прогон 03.10.

- n0 и n1 — число успешных платежей в двух окнах. Чек — выручка, делённая на число платежей, поэтому $N \times P$ даёт выручку точно.
- У partner_telecom платежей стало меньше на 72 %: 6 428 → 1 808. Чек почти не изменился: 324 → 325 ₽.
- По всем каналам: платежей 38 330 → 33 320, чек 324,38 → 324,68 ₽.


Метод цепных подстановок

Пекарня: в прошлом месяце продала 100 булок по 50 ₽, в этом — 90 булок по 60 ₽.



- Факторы меняют по одному: на каждом шаге один фактор переходит с базового значения на новое, остальные стоят на месте.
- Влияние фактора — на сколько изменился результат на его шаге: количество дало -500 ₽, цена — $+900$ ₽.
- Проверка: $-500 + 900 = +400 = 5\,400 - 5\,000$. Сумма влияний равна изменению всегда.

Почему порядок подстановок меняет ответ



Площадь — выручка. Синий контур — было, красный — стало.

- Количество: потеряли 10 булок по 50 ₪ — **-500**.
- Цена: по 10 ₪ на каждую из 100 булок — **+1 000**. Но 10 булок не продали, подорожание на них не случилось: -100.
- Эти -100 — **совместный член**: он есть, только когда меняются оба фактора.
- Он достаётся фактору, который меняют вторым. Сначала количество — цена даёт +900. Сначала цена — количество даёт -600.

Три порядка — три ответа, сумма одна

```
n0, p0, n1, p1 = 100, 50, 90, 60
orders = pd.DataFrame({
    "count_first": [(n1 - n0) * p0, n1 * (p1 - p0)],
    "price_first": [(n1 - n0) * p1, n0 * (p1 - p0)],
    "half": [(n1 - n0) * (p0 + p1) / 2, (p1 - p0) * (n0 + n1) / 2]},
    index=["by_count", "by_price"])
print(orders.astype(int))
print(orders.sum().astype(int).to_string())
```

	count_first	price_first	half
by_count	-500	-600	-550
by_price	900	1000	950
count_first	400		
price_first	400		
half	400		

Колонка — порядок: сначала количество, сначала цена, а half делит совместный член пополам. Сумма в каждой колонке одна —

+400 ₽.
Прогон 02.10.

Договорённость: сначала количество — «сколько», потом цена — «почём». Порядок пишут в подписи к разложению.

Функция chain: одна формула на все каналы

Каналов семь, считать придётся каждую неделю — подстановки оформляем функцией.

```
def chain(n0, p0, n1, p1):  
    by_count = (n1 - n0) * p0          # сначала количество  
    by_price = n1 * (p1 - p0)         # потом цена — при новом количестве  
    assert abs(by_count + by_price - (n1 * p1 - n0 * p0)) < 0.01  
    return round(by_count), round(by_price)  
  
print(chain(100, 50, 90, 60))  
pt = m.loc["partner_telecom"]  
print(chain(pt["n0"], pt["p0"], pt["n1"], pt["p1"]))
```

```
(-500, 900)  
(-1497671, 1691)
```

Функция возвращает два влияния в рублях.
У partner_telecom почти всё падение дало
число платежей.

m — таблица N и P с предыдущего слайда про ПРАЙМ. Окна 17–22.08 и 24–29.08: понедельник–суббота, сутки UTC, успешные платежи. Прогон 02.10.

assert внутри сверяет сумму влияний с
изменением при каждом вызове: ошибка
упадёт сразу, а не в отчёте.

Три фактора: подстановки — это цикл

Комиссия с покупок = операции × средний чек × ставка. Числа выдуманные.

```
x0 = {"ops": 1000, "chk": 2000, "rate": 0.015}
x1 = {"ops": 1100, "chk": 1800, "rate": 0.016}
def contrib(order):
    cur, out = dict(x0), {}
    for f in order:
        before = cur["ops"] * cur["chk"] * cur["rate"]
        cur[f] = x1[f]
        out[f] = round(cur["ops"] * cur["chk"] * cur["rate"] - before)
    return out
print(contrib(["ops", "chk", "rate"]))
print(contrib(["rate", "chk", "ops"]))
```

```
{'ops': 3000, 'chk': -3300, 'rate': 1980}
{'rate': 2000, 'chk': -3200, 'ops': 2880}
```

Цикл меняет факторы по одному. В обратном порядке влияния другие, а сумма та же: +1 680 ₽.

Прогон 02.10, окружение курса: pandas 3.0.5, без pyarrow.

Комиссию ПРАЙМ так раскладываете на семинаре — на своих данных.

Модели сочетают: сложение по каналам, умножение внутри

Канал	Влияние числа платежей, ₽	Влияние чека, ₽	Всего, ₽
partner_telecom	-1 497 671	+1 691	-1 495 980
organic	-61 793	+9 634	-52 159
social	-37 236	+6 401	-30 835
без канала	-25 965	+1 445	-24 520
crm	-21 796	-1 887	-23 683
referral	-16 222	+2 572	-13 650
performance	+36 790	-10 853	+25 937
ИТОГО	-1 623 893	+9 003	-1 614 890

Каждая строка — функция chain для одного канала. Сумма всех клеток равна изменению итога. Вывод: в одном канале стало меньше платежей, а сам платёж не подешевел.

Окна 17–22.08 и 24–29.08: понедельник–суббота, сутки UTC, успешные платежи; сначала число платежей. Прогон 02.10.

Эффект структуры: чек растёт без изменения цен

Пиццерия: маленькая пицца стоит 400 ₽, большая — 700 ₽, и цены не меняются.

```
price = pd.Series({"small": 400, "large": 700})  
share_before = pd.Series({"small": 0.6, "large": 0.4})  
share_after = pd.Series({"small": 0.5, "large": 0.5})  
print((price * share_before).sum(), (price * share_after).sum())
```

```
520.0 550.0
```

Цены не менялись, а средний чек вырос на 30 ₽: большая пицца стала занимать больше продаж.

Средний чек смешивает цену и структуру. Раскладывая его, проверьте, не сдвинулись ли доли сегментов.

Иначе «клиенты стали платить больше» окажется «стали чаще брать большую пиццу» — и решение примут не то.

Числа выдуманные. Прогон 02.10, окружение курса: pandas 3.0.5, без pyarrow.

Доли больше 100 % — показывайте рубли

Пекарня	₽	Доля
Количество	−500	−125 %
Цена	+900	+225 %
Изменение	+400	100 %

- Когда факторы тянут в разные стороны, их доли в изменении выходят за 100 %. Это не ошибка, но читатель решит, что ошибка.
- Доли от маленького изменения раздувают шум: при росте на 400 ₽ каждые 4 ₽ — это процент.
- Влияние факторов показывают в рублях — каскадной диаграммой. Круговая диаграмма отрицательное влияние не покажет вовсе.

График как аргумент


сначала вывод, потом форма

Сначала вывод — потом форма графика

Что вы хотите сказать	Форма	Пример на ПРАЙМ
Кто больше, кто меньше	столбики	выручка по каналам
Как менялось во времени	линия	выручка по дням
Из чего сложилось изменение	каскадная диаграмма	падение конца августа по каналам
Какую долю занимает часть	столбик 100 %	доля каналов в выручке
Как распределены значения	гистограмма	сумма покупки в партнёрском сервисе

- Форму выбирают под вывод, а не под данные: из одной таблицы можно нарисовать любой из пяти графиков.
- Заголовок графика — это вывод. Не «Выручка по неделям», а «Выручка упала на 13 % — из-за одного канала».

Каскадная диаграмма: тот же график — без трёх ошибок



Ось начинается с нуля, «без канала» на месте, окна равные, заголовок говорит вывод. Подписи округлены и дают 10,83 вместо 10,82: сумму проверяют на точных рублях, а не на подписях.

Окна 17–22.08 и 24–29.08: понедельник–суббота, сутки UTC, успешные платежи. Прогон 03.10, matplotlib 3.11.

Каскад: где стоит каждый столбик

```
d = t["delta"].sort_values(
    key=abs, ascending=False)
start, end = t["r0"].sum(), t["r1"].sum()
before = start + d.cumsum() - d
steps = pd.DataFrame(
    {"height": [start, *d, end],
     "bottom": [0, *before, 0]},
    index=["17-22.08", *d.index, "24-29.08"])
print(steps.round().astype(int))
```

	height	bottom
17-22.08	12433370	0
partner_telecom	-1495980	12433370
organic	-52159	10937390
social	-30835	10885231
performance	25937	10854396
без канала	-24520	10880333
crm	-23683	10855813
referral	-13650	10832130
24-29.08	10818480	0

- У столбика два числа: высота, height, и уровень, с которого он начинается, bottom. d — изменения каналов, от самого большого по модулю.
- Крайние столбики стоят на нуле: это выручка двух окон. Столбик канала начинается там, где закончился предыдущий, — этот уровень before копится через cumsum. У падения высота отрицательная: столбик идёт вниз.



t — таблица со слайда аддитивной модели. Прогон 03.10, окружение курса: pandas 3.0.5, без pyarrow.

Каскад: рисуем

```
colors = ["#6B7280", *np.where(d < 0, "#C1272D", "#2A9D8F"), "#6B7280"]
labels = [f"{start / 1e6:.2f}", *(f"{v / 1e6:+.2f}" for v in d),
          f"{end / 1e6:.2f}"]
labels = [x.replace(".", ",").replace("-", "-") for x in labels]
fig, ax = plt.subplots(figsize=(11, 4.6), layout="constrained")
bars = ax.bar(steps.index, steps["height"], bottom=steps["bottom"],
              color=colors, zorder=2)
ax.bar_label(bars, labels=labels, padding=2)
ax.tick_params(axis="x", labelrotation=20)
ax.set_title("Выручка упала на 1,6 млн Р — почти целиком из-за partner_telecom",
            loc="left")
ax.set_ylabel="млн Р", ylim=(0, start * 1.1)) # ось от нуля
ax.yaxis.set_major_formatter(lambda y, _: f"{y / 1e6:.0f}")
ax.spines[["top", "right"]].set_visible(False)
ax.grid(axis="y", color="#E5E7EB")
fig.savefig("каскад-исправленный.pdf", bbox_inches="tight")
```

Главная строка — `ax.bar(..., bottom=...)`: столбики с заданным нижним уровнем.
Остальное — оформление: цвет по знаку, подписи в млн Р, заголовок-вывод, ось от нуля.
Шрифт — `plt.rcParams["font.size"] = 16`. Прогон 03.10, matplotlib 3.11.



У столбиков ось — с нуля



- Длина столбика и есть число. Слева столбики различаются по высоте втрое, а выручка — на 13 %.
- У линии ось можно начинать не с нуля: она показывает изменение, а не величину. Но шкалу подписывают.

Выручка. Окна 17-22.08 и 24-29.08: понедельник-суббота, сутки UTC, успешные платежи. Прогон 03.10.



Один цвет — для того, о чём вывод



- Семь цветов и легенда заставляют сверять цвета, а не читать вывод.
- Фон рисуют серым, а предмет вывода — одним акцентным цветом и подписывают прямо у линии, без легенды.

Недельная выручка по каналам, недели с 1 июня по 23 августа 2026 года. Прогон 03.10.

Неполный период на графике выглядит как обвал



- Слева неделя с 24.08 ниже предыдущей на 18 %, а в пересчёте на день — на 12 %: треть «обвала» дают полдня 30 августа.
- Справа неделя пересчитана в выручку за день и подписана: неполный период пересчитывают или отрезают — и пишут об этом на графике.


Недельная выручка, недели с понедельника, сутки UTC. Прогон 03.10.

Типовые искажения

Искажение	Что видит читатель	Что делать
Ось столбиков не с нуля	разница выглядит в разы больше настоящей	ось с нуля
Две оси Y	ряды «пересекаются» там, где автор выбрал масштаб	два графика рядом
Площадь или объём вместо длины	круг вдвое шире кажется вчетверо больше	столбики
Накопленная сумма вместо динамики	линия растёт всегда, даже при падении	показывать за период
Сглаживание	скользящее среднее прячет событие — как дыру 14–15 апреля на Л5	сырой ряд рядом

Ни одно искажение не требует неверных чисел: все числа на таких графиках правильные.

Деловой график: до и после



```
ax.yaxis.set_major_formatter(FuncFormatter(
    lambda y, _: f"{y / 1e6:.2f}".replace(".", ",") + " млн"))
ax.spines[["top", "right"]].set_visible(False)
ax.annotate("27 073 отмены partner_telecom", arrowprops={"arrowstyle": "->"},
            xy=(pd.Timestamp("2026-08-22"), aug["2026-08-22"]),
            xytext=(-210, -20), textcoords="offset points")
ax.set_title("С 22.08 выручка ниже на ~240 тыс. ₽ в день", loc="left")
```

Заголовок говорит вывод, единицы подписаны на оси, лишние рамки убраны, событие подписано прямо на графике, а источник стоит мелко внизу.

Дневная выручка 01–29.08.2026, сутки UTC. Фрагмент кода правого графика. Прогон 03.10, matplotlib 3.11.

Вывод для заказчика

что случилось, за счёт чего, что делать

Вывод за 30 секунд

1. **Что случилось:** число, период и с чем сравнили
2. **За счёт чего:** разложение
3. **Чего мы не знаем**
4. **Что делать:** действие, кто, когда

Плохо: «Выручка снизилась на 13 %. Это может быть связано с разными факторами, требуется дополнительный анализ».

Хорошо: «Выручка от подписок 24–29 августа — 10,82 млн ₽, на 1,61 млн (13 %) ниже тех же дней неделей раньше. 1,50 млн из них — канал `partner_telecom`: 22 и 23 августа разом закончились 27 тыс. его подписок. Пять других каналов изменились не больше чем на 2 %. Почему ушли подписки, мы не знаем: 27 073 из 27 179 отмен пришлось ровно на полночь — это похоже на операцию на стороне партнёра. Предлагаю сегодня запросить у партнёра причину и, если это сбой, восстановить подписки».

Чего разложение не доказывает

Разложение отвечает **«за счёт чего»**, а не **«почему»**.

- Влияние фактора — это арифметика: «-1,5 млн ₽ дало число платежей». Причину арифметика не называет.
- Причину проверяют экспериментом или вопросом тому, кто знает. Эксперименты — темы 07–08.

Подписки по ended_at, канал — владельца. Прогон 02.10.

Что подсказывают данные

Отмен ровно в 00:00:00 UTC, 22.08	13 689
Отмен ровно в 00:00:00 UTC, 23.08	13 981
Всего за две ночи	27 670
из них partner_telecom	27 073
из них без канала	597
Максимум отмен в одну секунду за остальную историю	2
Отмены ровно в полночь не похожи на решения людей. Гипотезу о пакетной операции партнёра проверяют у партнёра.	

Проект 1: что из сегодняшнего пригодится

Критерий	Доля
Корректность расчёта метрик и факторной декомпозиции	35 %
Качество визуализации и делового вывода	25 %

- Сумма влияний факторов сходится с изменением — проверено кодом.
- Порядок подстановок и окна сравнения названы в подписи.
- Каждый из 3–5 графиков что-то доказывает, и заголовок говорит вывод.
- Записка идёт по схеме: что случилось → за счёт чего → чего не знаем → что делать.



репозиторий курса →
проекты/проект-1

Сдача **25.10**, 23:59.
Защиты **26.10–06.11.**

Что унести с этой пары

- **Факторный анализ** раскладывает изменение показателя на влияния факторов, и их сумма равна изменению. Не сходится — что-то потеряли.
- **Цепные подстановки** меняют факторы по одному. Порядок — часть определения: совместный член достаётся второму.
- **Модели сочетают:** по сегментам — сложением, внутри сегмента — умножением.
- **Сначала вывод, потом форма графика.** Заголовок — это вывод.
- **У столбиков ось с нуля, акцентный цвет — один, неполный период помечен.**
- **Разложение отвечает «за счёт чего», а не «почему».**

Семинары С5 и С6: среда 07.10 — в 18:10, суббота 10.10 — в **13:00**, а не в 9:30. Что подготовить — в README темы 05.