Программирование на Python для бизнес-аналитики

Магистратура «Бизнес-аналитика и цифровые решения в финансах» · ВШБ НИУ ВШЭ

Пилоты и эксперименты: постановка и дизайн

Антон Катков · 7 ноября 2026

От декомпозиции к причинному выводу

На Л6 падение выручки было разложено по каналам: 93 % изменения пришлось на канал partner_telecom.

Факторная декомпозиция отвечает на вопрос **«за счёт чего»:** какие составляющие показателя изменились и на сколько.

На вопрос **«почему»** — что вызвало изменение — она не отвечает.

- Декомпозиция — арифметическое тождество: сумма вкладов равна изменению показателя. Причинной информации в ней нет.
- Причинное утверждение «изменение X вызвало изменение Y» требует данных, в которых X менялся независимо от прочих факторов.
- Такие данные получают в эксперименте. Предмет этой лекции — постановка эксперимента, результату которого можно доверять; следующей — анализ его результатов.

Пилот и три вопроса, на которые он отвечает

Пилот — ограниченное по охвату внедрение изменения, организованное так, чтобы по собранным данным получить обоснованную оценку его причинного эффекта на заранее зафиксированную целевую метрику.

Вопрос	Что оценивается
какая версия лучше	знак эффекта
насколько	величина эффекта в единицах метрики
можно ли доверять оценке	отсутствие смещения и отличие от случайных колебаний

- Возможность доверять результату закладывается ещё при проектировании эксперимента.
- До запуска фиксируются: целевая метрика и правило её расчёта, определение воздействия, механизм назначения в группы, уровень значимости, мощность, минимальный детектируемый эффект (MDE), горизонт наблюдения.
- Параметр, выбранный после получения данных, может быть подобран под желаемый результат — в том числе без умысла. Предварительная фиксация исключает эту свободу.

Сквозной пример: кэшбэк 5 % на доставку

Гипотеза продуктовой команды
Повышение кэшбэка на доставку для подписчиков Базового тарифа с 1 до 5 % увеличит их оборот в партнёрских сервисах экосистемы.

Кэшбэк финансирует партнёр доставки; ПРАЙМ получает комиссию с оборота в партнёрских сервисах.

Группа	Условия
control	условия не меняются: кэшбэк на доставку 1 %, уведомлений нет
test_1	кэшбэк на доставку 5 %
test_2	условия прежние (1 %), клиенту отправляется push-уведомление с напоминанием о кэшбэке на доставку

- Совокупность: 12 000 владельцев действующих подписок Базового тарифа на 31.08.2026.
- Окно пилота — 4 недели, 31.08–27.09.2026.

Сквозной пример: кэшбэк 5 % на доставку

Гипотеза продуктовой команды
Повышение кэшбэка на доставку для подписчиков Базового тарифа с 1 до 5 % увеличит их оборот в партнёрских сервисах экосистемы.

Кэшбэк финансирует партнёр доставки; ПРАЙМ получает комиссию с оборота в партнёрских сервисах.

- Совокупность: 12 000 владельцев действующих подписок Базового тарифа на 31.08.2026.
- Окно пилота — 4 недели, 31.08–27.09.2026.

Группа	Условия
control	условия не меняются: кэшбэк на доставку 1 %, уведомлений нет
test_1	кэшбэк на доставку 5 %
test_2	условия прежние (1 %), клиенту отправляется push-уведомление с напоминанием о кэшбэке на доставку

- test_1 проверяет эффект изменения условий.
- test_2 проверяет эффект уведомления без изменения условий. Если он есть, повышать кэшбэк, возможно, не требуется.

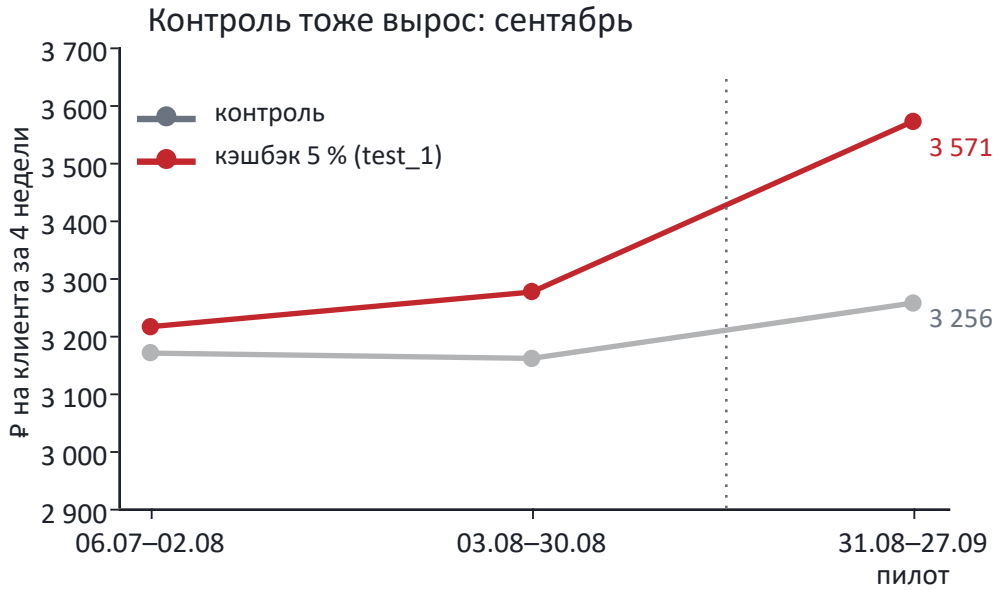
Данные пилота

Таблица	Содержание
`pilot_candidates`	кандидаты в пилот: признаки и показатели за два периода до запуска (июль и август)
`pilot_assignment`	журнал назначения в группы — в том виде, в каком его сформировал сервис
`pilot_outcomes`	показатели клиентов за период пилота
`rollout_telecom`	та же опция, включённая партнёром для своих абонентов без рандомизации

- Данные синтетические и находятся в схеме prime учебного сервера.
- Истинные эффекты заложены в генератор и известны. Это позволяет сопоставить оценки разных методов с истинным значением — в реальных данных такой возможности нет.
- В этой лекции используется только `pilot_candidates`: результаты пилота ещё не получены.

Описание таблиц и генератор — данные/пилот/. Итоги пилота и квазиэксперимент — на Л8.

Почему сравнение «до и после» может дать неверную оценку эффекта



- Группа с кэшбэком: 3 276 ₽ в августе, 3 571 ₽ в сентябре — прирост **295 ₽**.
- Контрольная группа воздействия не получала, однако её показатель вырос на 94 ₽ (+3 %): изменение без воздействия (в т. ч. сезонность).
- Оценка «до и после» по одной группе отнесла бы эти 94 ₽ к эффекту кэшбэка. Различить по одному временному ряду действие изменения, сезонность и внешние факторы невозможно.

Средний оборот в партнёрских сервисах на клиента за 4 недели. Периоды: 06.07–02.08, 03.08–30.08, 31.08–27.09. Прогон 12.10.

Потенциальные исходы и роль контрольной группы

Для клиента i определены два **потенциальных исхода:**

- $Y_i(1)$ — оборот при получении воздействия;
- $Y_i(0)$ — оборот без воздействия.

Индивидуальный эффект $\tau_i = Y_i(1) - Y_i(0)$. Реализуется ровно один исход, второй остаётся контрфактическим — фундаментальная проблема причинного вывода (Holland, 1986).

i	воздействие	*Y(1)*	*Y(0)*
1	да	4 120	?
2	нет	?	2 870
3	да	3 050	?

- Поэтому оценивается средний эффект, а ненаблюдаемый исход *Y(0)* аппроксимируется группой, не получившей воздействия, — контрольной.
- Сезонные и внешние факторы действуют на обе группы и сокращаются при сравнении.
- Условие корректности — сопоставимость групп до воздействия. Его обеспечивает случайное назначение.

ATE, ATT и ATC: для какой группы считаем эффект

Обозначения: $\tau_i = Y_i(1) - Y_i(0)$ — индивидуальный эффект клиента i;
$D_i = 1$ — воздействие получено, $D_i = 0$ — не получено.

ATE

Вся целевая совокупность

$$ATE = \mathbb{E}[\tau_i]$$

Средний эффект для всех клиентов, к которым относится исследование.

Запуск на всю аудиторию

ATT

Получившие воздействие

$$ATT = \mathbb{E}[\tau_i \mid D_i = 1]$$

Средний эффект для тех, кто фактически получил воздействие.

Эффект у участников теста

ATC

Не получившие воздействие

$$ATC = \mathbb{E}[\tau_i \mid D_i = 0]$$

Средний эффект для контроля, если бы он получил воздействие.

Перенос эффекта на контроль

$ATE = p \cdot ATT + (1 - p) \cdot ATC$, где $p = P(D_i = 1)$ — доля получивших воздействие.

При корректной рандомизации ATE = ATT = ATC

При самовыборе и разных эффектах у разных клиентов эти величины могут различаться.

Два сценария: рандомизированный и наблюдательный

А/Б-тест — назначение воздействия случайно и находится под контролем исследователя. Частный случай рандомизированного контролируемого испытания (РКИ).

Наблюдательный сценарий: назначение уже произошло вне контроля исследователя и/или не было случайным. Группы могут систематически различаться до воздействия.

- Сценарии различаются способом получения данных.
- Мэтчинг (подбор сопоставимых наблюдений) — метод оценки эффекта по собранным данным. Он применим и к данным А/Б-теста, где учитывает остаточный дисбаланс.
- Это один из методов оценки в наблюдательном сценарии.
- Мэтчинг не превращает наблюдательные данные в эксперимент: он учитывает небольшие смещения по наблюдаемым признакам — и только их.

Иерархия доказательств: Guyatt, 1995; Greenhalgh, 2014. Мэтчинг — на Л8.

Гипотеза

от предположения к проверяемому утверждению

Проверяемая гипотеза

Гипотеза — это проверяемое предположение о явлении или связи между переменными, которое можно подтвердить или опровергнуть с помощью данных и эксперимента.

Структура

Если **[изменение]** для **[совокупности]**, то **[метрика]** изменится не менее чем на **[порог]** за **[горизонт]**, поскольку **[механизм]**.

Непроверяемая формулировка: «Кэшбэк повысит лояльность».
Не определены метрика, величина ожидаемого изменения и горизонт наблюдения.

Проверяемая формулировка:

Если владельцам подписок Базового тарифа повысить кэшбэк на доставку с 1 до 5 %, то их оборот в партнёрских сервисах за 4 недели вырастет не менее чем на 200 ₽ на клиента, поскольку доставка внутри экосистемы станет выгоднее внешних альтернатив.

- Указание механизма определяет вспомогательные метрики: число покупок, доля доставки в обороте.
- Порог 200 ₽ выбран для решения; MDE настроен на его обнаружение — раздел «Объём и длительность».

Бизнес-вопрос и решающее правило

- Пилот оправдан, если от его результата зависит управленческое решение. В противном случае это исследование, и его стоимость оценивается иначе.
- До запуска формулируется **решающее правило:** какое действие следует из каждого возможного исхода.
- Правило заранее согласуют с заказчиком. После получения результата не приходится заново обсуждать, как его интерпретировать.

Исход	Решение
эффект значим, оценка ≥ порога, защитные метрики без ухудшения	тиражировать изменение
эффект значим, защитная метрика ухудшилась	доработать и повторить пилот
эффект не значим, интервал целиком ниже порога	не тиражировать
эффект не значим, интервал широкий	данных недостаточно: продлить или закрыть

Защитные метрики (guardrail metrics) — показатели, для которых заранее определяют допустимые пределы ухудшения.

Экспериментальная единица

что является наблюдением

Выбор единицы рандомизации

Единица	Когда уместна	Риск в данных ПРАЙМ
клиент	воздействие адресовано человеку: предложение, цена, интерфейс	участники одной подписки попадают в разные группы
подписка	воздействие затрагивает всех пользователей подписки	меньше единиц, кластеры разного размера
устройство	интерфейсные изменения без авторизации	один клиент с разных устройств — в разных группах
регион	цена, логистика, офлайн-партнёры	89 единиц: маленькая выборка и большая дисперсия

- Принцип: единица рандомизации задаёт независимые единицы анализа. Назначение по клиентам — расчёт по клиентам.
- В нашем пилоте единица — **владелец подписки:** кэшбэк начисляется плательщику, участники подписки условий не видят.

Совместное пользование подпиской и взаимное влияние групп

- У 66 % кандидатов к подписке подключены участники — один или двое.
- При назначении по отдельным клиентам участник из контрольной группы мог бы оформлять доставку через владельца из тестовой. Контрольная группа частично получила бы воздействие.
- Оценка эффекта в этом случае смещена к нулю: различие групп меньше истинного эффекта.

Предпосылка сравнения: исход для клиента зависит только от его собственного назначения, но не от назначения других клиентов (SUTVA).

Её нарушают: совместное пользование, реферальные механики, общий бюджет домохозяйства.

Нарушение устраняется выбором единицы: назначаются не клиенты, а подписки или территории.

Несовпадение единиц рандомизации и анализа

Симуляция без эффекта. 6 000 клиентов 1 000 раз случайно делятся на две группы по 3000. Метрика — средний чек.

Единица анализа	Отвержений H_0
покупка (27 579 наблюдений)	18,5 %
клиент (6 000 наблюдений)	4,7 %

Номинальный уровень — 5 %: эффекта в данных нет.

- Покупки одного клиента коррелированы: у клиента устойчивый средний чек.
- Критерий трактует 27 тыс. покупок как независимые наблюдения, тогда как независимых единиц 6 тыс. Стандартная ошибка занижается, и ошибка I рода превышает номинальную более чем втрое.
- Корректная процедура: агрегировать данные до единицы рандомизации (`groupby("client_id")`) и сравнивать агрегаты.

Генератор пилота, 6 000 клиентов, покупки развёрнуты в строки; критерий Уэлча, $\alpha = 0{,}05$. Прогон 12.10.

Метрики

что измеряется и что не должно ухудшиться

Основная, вспомогательные и защитные метрики

Роль	В нашем пилоте
основная	оборот в партнёрских сервисах на клиента за 4 недели, ₽
вспомогательные	число покупок; доля доставки в обороте
защитные	отток подписки; обращения в поддержку; доля переходов на Расширенный тариф

- **Основная** метрика одна: по ней рассчитываются MDE и объём выборки и по ней принимается решение.
- **Вспомогательные** метрики описывают механизм: растёт число покупок или их средняя сумма.
- **Защитные метрики** — без ухудшений. Повышенный кэшбэк на Базовом тарифе может снизить стимул к переходу на Расширенный за **399 ₽ —** эффект каннибализации.

Тарифы — prime.tariffs: Базовый 199 ₽, Расширенный 399 ₽; кэшбэк 1 % и 3 %.

Требования к основной метрике

1. **Связь с решением:** изменение вводится ради оборота.
2. **Определена на единице рандомизации:** на клиенте, а не на покупке.
3. **Определена для всех наблюдений:** отсутствие покупок — нулевой оборот, а не пропуск. В августе 6,1 % кандидатов не совершили ни одной покупки.
4. **Чувствительность:** изменение успевает проявиться за горизонт пилота.
5. **Наличие предыстории:** та же метрика за прошлые периоды позволяет снизить дисперсию оценки.

Недопустимая метрика: «оборот среди открывших push-уведомление».

Факт открытия уведомления определяется уже после назначения и зависит от активности клиента. Такая метрика сравнивает разные подвыборки клиентов, а не группы, сформированные рандомизацией. Величина возникающего смещения — на Л8.

Доля нулевых значений — по spend_prev в pilot_candidates. Прогон 12.10.

Группы и рандомизация

механизм назначения в группы

Две стадии А/Б-теста

Стадия 1. Назначение воздействия

Определяется, кто в какую группу попадает. Часто назначение случайно — это и делает А/Б-тест частным случаем РКИ.

Необязательный этап: рерандомизация — из множества случайных разбиений отбирается наилучшее по балансу наблюдаемых признаков.

Стадия 2. Подведение итогов

Выбирается эстиматор:

- разность средних (t-критерий);
- CUPED и CUPAC — снижение дисперсии по предпериоду;
- мэтчинг — учёт небольших смещений между группами.

- Рерандомизация смещает баланс в сторону наблюдаемых признаков: по ним группы выравниваются, относительно неизмеренных дополнительных гарантий не возникает. Её эффект может быть как положительным, так и отрицательным.
- Предмет этой лекции — стадия 1; стадия 2 рассматривается на Л8.

AA-тест: проверка процедуры по ошибкам I и II родов

Ошибка I рода — обнаружение несуществующего эффекта.

- Разбиение многократно повторяется на данных без воздействия; применяется тот же критерий, что и в основном анализе.
- Доля отвержений H_0 должна быть близка к α.
- Превышение указывает на нарушение предпосылок: неверную единицу анализа, выбросы, ошибку в механизме разбиения.

Ошибка II рода — пропуск существующего эффекта.

- В одну из групп вносится синтетический эффект размера MDE.
- Доля обнаружений должна быть близка к заявленной мощности.

Августовские данные, 2 000 разбиений по 4 000 клиентов

Проверка	Доля
отвержений H_0 без **эффекта**	5,4 %
обнаружений **эффекта** +200 ₽	78,3 %
то же с поправкой CUPED по июлю	91,6 %

В HypEx класс AATest контролирует ошибку I рода и отбирает разбиение. Проверка ошибки II рода реализуется отдельно — на семинаре.

Метрика spend_prev, критерий Уэлча, α = 0,05; ковариата CUPED — spend_prev2. Прогон 12.10.

Стратифицированное разбиение на три группы в HypEx

```
from hypex import AATest
from hypex.dataset import (Dataset, InfoRole,
    StratificationRole, TargetRole)

cand["acquisition_channel"] = (
    cand["acquisition_channel"].fillna("no_channel"))

ds = Dataset(roles={
        "client_id": InfoRole(str),
        "acquisition_channel": StratificationRole(),
        "spend_prev": TargetRole(),
        "sessions_prev": TargetRole()},
    data=cand, default_role=InfoRole())

aa = AATest(groups_sizes=[1/3, 1/3, 1/3],
            stratification=True,
            n_iterations=30).execute(ds)
split = aa.best_split.data       # + column split
```

- Колонки датасета размечаются ролями; эксперимент находит нужные поля по ролям.
- `default_role=InfoRole()`: неперечисленные колонки в расчётах не участвуют.
- При стратификации каждая страта (канал привлечения) делится на три части отдельно.
- Пропуск в страте образует отдельную страту. Без `fillna` 611 клиентов без канала выпадут из стратификации (см. тему 03).

HypEx 1.0.7. В ноутбуке семинара значение пропуска — «без канала»; здесь латиница из-за ограничений listings.

Результат AA-теста

метрика	группа	aa test	best split	разница
spend_prev	test_1	OK	OK	+39,6 ₽
spend_prev	test_2	OK	OK	+12,0 ₽
sessions_prev	test_1	OK	OK	+0,04
sessions_prev	test_2	OK	OK	+0,01

Доли каналов привлечения в группах:

канал	control	test_1	test_2
organic	0,3130	0,3123	0,3130
performance	0,1764	0,1765	0,1764
без канала	0,0508	0,0512	0,0508

- **aa test —** итог по 30 разбиениям: удерживается ли доля отвержений вблизи α. Характеризует процедуру; погрешность оценки ±0,04 (приложение).
- **best split —** характеристика одного отобранного разбиения, используемого в пилоте.
- Учитываются обе колонки: удачное разбиение не компенсирует некорректную процедуру.
- Стратификация выровняла доли каналов с точностью до третьего знака.

aa.resume и pd.crosstab(..., normalize="columns"), сокращено. 12 000 кандидатов, 30 итераций. Прогон 12.10.

Объём и длительность

объём выборки и горизонт наблюдения

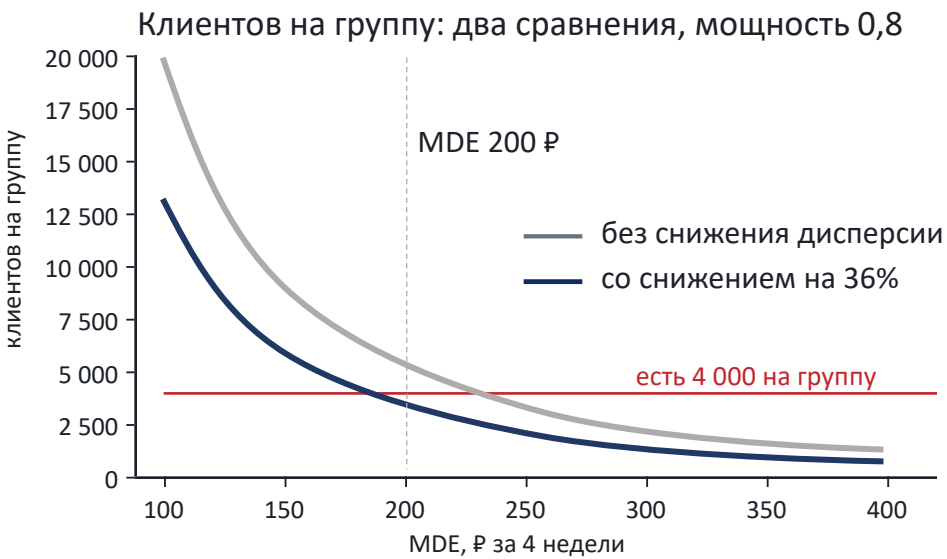
Объём выборки: связь пяти величин

$$n \approx 2\left(z_{1-\alpha/2} + z_{1-\beta}\right)^2 \frac{\sigma^2}{MDE^2}$$

α	уровень значимости, обычно 0,05
$1-\beta$	мощность, обычно 0,8
σ	стандартное отклонение метрики
MDE	минимальный детектируемый эффект
n	объём каждой группы
z	квантиль стандартного нормального распределения

- Четыре величины задаются, пятая определяется однозначно. Если объём выборки ограничен, тем самым определён и MDE.
- MDE ∝ 1/√n: для уменьшения MDE вдвое объём выборки увеличивается вчетверо.
- MDE ∝ σ: снижение дисперсии метрики эквивалентно увеличению выборки и не требует дополнительных наблюдений.
- Мощность, рассчитанная по уже полученному p-значению (observed power), не несёт новой информации. Мощность рассчитывается до запуска.

Выполнимость дизайна



август: среднее, σ	3 193 и 3 288 ₽
MDE	200 ₽ (6,3 %)
требуется, одно сравнение	4 242
требуется, два сравнения	5 138
доступно на группу	4 000
ρ (июль, август)	0,597
требуется со снижением на ρ^2	3 306

Без снижения дисперсии дизайн невыполним. Это учитывают при проектировании, до анализа итогов.

Два сравнения — α/2 на каждое (Бонферрони). ρ^2 — по двум прошлым периодам. Расчёт в HypEx — приложение и C7. Прогон 12.10.

Длительность пилота

- **Целое число недель.** Покупательская активность различается по дням недели; окно в 10 дней смещает метрику (см. тему 05).
- **Цикл списаний — 30 дней.** При более коротком окне часть подписок не достигнет даты продления, и отток не успеет проявиться (см. тему 06).
- **Эффект новизны.** В первые дни изменение используют из любопытства. Если интересует устойчивый эффект, окно удлиняют, а первую неделю анализируют отдельно.
- **Набор выборки.** Если клиенты приходят постепенно, длительность определяется временем набора n.

Выбранный горизонт: 4 недели, 31.08–27.09.

Все 12 000 клиентов доступны с первого дня; горизонт определяется циклом списаний и временем формирования покупательской привычки.

Дата окончания фиксируется заранее. Ежедневная проверка p-значения с остановкой при достижении значимости завышает ошибку I рода — количественно на Л8.

Ограничения и смещения

ограничения и источники смещения

Ограничения экспериментов в финансовых продуктах

Ограничение	Пример	Подход
неделимое изменение	цена тарифа, ключевая ставка, норма закона	наблюдательное исследование, сравнение территорий
требование равных условий	условия для клиентов одной категории должны совпадать	проверяется коммуникация, а не условия
назначение вне контроля	партнёр самостоятельно включил опцию своим абонентам	квазиэкспериментальные методы — Л8
малое число единиц	89 регионов, 7 партнёров	более длительное наблюдение, стратификация
отложенный эффект	отток через полгода, LTV	ранняя суррогатная метрика с проверкой её связи с целевой
высокая цена ошибки	кредитный лимит, скоринг	малая доля тестовой группы, строгие пороги защитных метрик

Выводы, полученные без рандомизации, опираются на дополнительные непроверяемые допущения и формулируются осторожнее.

Источники смещения и нарушения протокола

Нарушение	Как проявляется
дисбаланс размеров групп (SRM)	критерий χ^2 согласия с заданными долями
перекрёстное назначение	клиент записан в две группы
утечка воздействия	контрольная группа узнаёт о предложении
отбор после воздействия	анализ «среди открывших уведомление»
промежуточные проверки	остановка при достижении значимости
эффект новизны	различие эффекта в первую и последующие недели

Журнал назначения нашего пилота: 12 055 записей на 12 000 клиентов.

После обновления сервиса 02.09 у 55 клиентов появилась вторая запись — test_2; 30 из них ранее были назначены в контроль, 25 — в test_1.

Соединение журнала с итогами без обработки повторов учтёт этих клиентов дважды (см. тему 04).

prime.pilot_assignment: группировка по client_id, nunique(grp) > 1. Обработка — на Л8. Прогон 12.10.

Дизайн-документ пилота

Пункт	Наш пилот
гипотеза	кэшбэк 5 % → оборот ≥ +200 ₽
единица	владелец подписки Базового тарифа
группы	3 по 4 000, страты — канал привлечения
основная метрика	Оборот с партнерами за 4 недели, ₽
защитные метрики	отток, обращения, переходы на Расширенный тариф
α, мощность, MDE	0,05 · 0,8 · 200 ₽
поправка	Холм для двух основных сравнений
метод оценки	t-test после CUPED по августу
окно	31.08–27.09, без досрочной остановки
решающее правило	раздел «Гипотеза»

- Документ составляется до запуска и хранится там, где фиксируется дата: в репозитории, в системе задач.
- Всё, что может быть подобрано под желаемый результат, фиксируется до того, как результат известен.
- Без такого документа итоги пилота не с чем сопоставить: анализ на Л8 опирается именно на него.

Что фиксируется до получения данных



- Решения слева от границы принимаются до получения результатов.
- Справа анализ ведётся только по правилам, зафиксированным заранее. Замена метрики, поправки или исключение сегментов после просмотра данных — уже не проверка гипотезы, а поиск значимого результата.

Итоги лекции

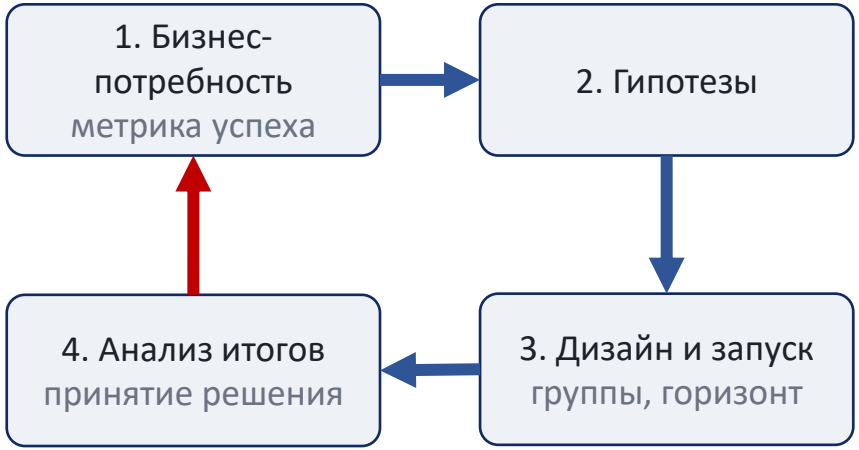
- Оценка «до и после» включает всё, что изменилось за тот же период. Контрольная группа учитывает изменения без воздействия: контроль вырос на 94 ₽.
- Проверяемая гипотеза содержит метрику, порог эффекта, горизонт и механизм. Правило формулируется до запуска.
- Анализ учитывает единицу рандомизации; при игнорировании кластеров ошибка I рода составила 18 % вместо 5 %.
- Основная метрика одна, защитные метрики обязательны. Метрика по событию после назначения, недопустима.
- AA-тест проверяет процедуру по ошибкам обоих родов; best split характеризует одно разбиение.
- n, MDE, σ, α и мощность связаны одним соотношением. Наш дизайн выполним только при снижении дисперсии.

Семинар С7: гр. А — ср 11.11, 18:10; гр. Б — сб 14.11, 13:00. Окружение с HypEx 1.0.7 устанавливается до семинара — README темы 07.

Приложение

для самостоятельного чтения

Цикл проверки гипотез



- Этапы 1–3 рассматриваются на Л7, этап 4 — на Л8.
- Отрицательный результат полезен, если интервал исключает практически важный эффект. Иначе вывод — данных пока недостаточно для окончательного решения.
- Организация, систематически проходящая этот цикл, накапливает не перечень внедрений, а свод проверенных утверждений о том, какие воздействия результативны для её клиентов.

Погрешность оценки ошибки I рода в AA-тесте

$$SE \approx \sqrt{\frac{\alpha(1-\alpha)}{k}}$$

При k = 10 итерациях SE = 0,069 — больше самого α. По десяти разбиениям корректную процедуру нельзя отличить от процедуры с вдвое завышенной ошибкой I рода.

итераций	SE	время
10	0,069	11 с
30	0,040	26 с
100	0,022	84 с
2 000 (precision_mode)	0,005	≈ 28 мин

- Рекомендация: дизайн отрабатывается на 10–30 итерациях; перед запуском выполняется однократная проверка с большим числом итераций.
- early_stopping=True останавливает перебор на первом сбалансированном разбиении. Это быстро, но aa_score после такой остановки ошибку I рода не оценивает.
- Типичные ошибки подготовки данных — ConstGroupRole с np.nan, MinSampleSize без колонки групп — разбираются на семинаре.

Три группы, стратификация по каналу, две метрики. Время для 2 000 итераций экстраполировано по 100. Прогон 12.10.

Расчёт объёма выборки в HypEx

```
from hypex.executor.calculators import MinSampleSize

pair = split[split["split"] != "test_2"]
ds = Dataset(roles={
        "client_id": InfoRole(str),
        "split": TreatmentRole(),
        "spend_prev": TargetRole()},
    data=pair, default_role=InfoRole())

MinSampleSize(mde=200.0, alpha=0.05,
              equal_variance=True).calc(data=ds)
# {'overall': {'min sample size': 4296}}
```

- MinSampleSize — калькулятор: вызывается через .calc().

- MDE задаётся в единицах метрики (рублях), а не в процентах.
- Требуется колонка с TreatmentRole: дисперсии оцениваются внутри групп. Без неё — No group keys passed!
- 4 296 против 4 242 по формуле: калькулятор оценивает дисперсию внутри групп, формула — по всей выборке.