Программирование на Python для бизнес-аналитики

Магистратура «Бизнес-аналитика и цифровые решения в финансах» · ВШБ НИУ ВШЭ

Анализ результатов пилота: эксперимент и квазиэксперимент

Антон Катков · 7 ноября 2026

Исходные условия анализа

Пункт	Зафиксировано в дизайн-документе (Л7)
группы	control; test_1 — кэшбэк 5 %; test_2 — прежние условия и push-уведомление
основная метрика	оборот в партнёрских сервисах на клиента за 4 недели
защитные метрики (guardrail metrics)	отток, обращения в поддержку, переходы на Расширенный тариф
α · мощность · MDE	0,05 · 0,8 · 200 ₽
поправка	метод Холма
метод оценки	CUPED по августовскому обороту
окно	31.08–27.09.2026

- Параметры дизайна при анализе не пересматриваются. Их изменение после получения данных превращает проверку гипотезы в поиск значимого результата.
- Порядок анализа: подготовка данных → оценка эффекта и доверительного интервала → снижение дисперсии → источники ложных выводов → оценка без рандомизации → решение и отчёт.
- Расчёты выполняются в HypEx 1.0.7 и воспроизводятся вручную.

ЛЕКЦИЯ 08 / 01

Подготовка данных

проверки до оценки эффекта

Журнал назначения: 12 055 записей на 12 000 клиентов

```
n_grp = asg.groupby("client_id")["grp"].nunique()
both = n_grp[n_grp > 1].index          # 55 clients

clean = (asg[~asg["client_id"].isin(both)]
         .drop_duplicates("client_id"))
df = (cand.merge(clean, on="client_id",
                 validate="one_to_one")
      .merge(out, on="client_id",
             validate="one_to_one"))
len(df)                                # 11945
```

- После обновления сервиса 02.09 у 55 клиентов появилась вторая запись — test_2. Они получили push-уведомление, будучи назначены в другую группу.
- Исключение этих клиентов требует обоснования: сбой не должен зависеть от потенциального исхода. Первичный ITT-анализ по исходному назначению — полезная проверка.
- Число исключённых и основание исключения указываются в отчёте.
- Параметр validate= выявляет повтор ключа до удвоения оборота (см. тему 04).

Из 55 клиентов 30 первоначально назначены в контроль, 25 — в test_1. Альтернатива — анализ по первоначальному назначению с указанием этого в отчёте. Прогон 12.10.

Проверка соотношения размеров групп (SRM)

```
from scipy import stats

sizes = df["grp"].value_counts()
stats.chisquare(sizes)        # equal shares
# statistic=2.12, pvalue=0.346
```

	control	test_1	test_2
после очистки	3 911	3 995	4 039
«открывшие push»	3 911	1 702	1 667

- Назначение выполнялось в равных долях; наблюдаемые размеры с ними согласуются: p = 0,35.
- Расхождение (sample ratio mismatch, SRM) сигнализирует о возможной ошибке назначения или отбора. Причину нужно выяснить до интерпретации эффекта.
- Вторая строка — состав групп при отборе только открывших уведомление: $p \approx 10^{-296}$.

Критерий χ^2 согласия с равными долями. Прогон 12.10.

Отбор по событию после назначения смещает оценку

test_1 против контроля	эффект	95 % ДИ
вся группа	+315 ₽	161…468
только открывшие push	+1 321 ₽	1 090…1 552
истинный эффект	+197 ₽	

Уведомление открыли 43 % группы — преимущественно наиболее активные клиенты.

- Открытие уведомления происходит после назначения и зависит от активности клиента. В контрольной группе аналогичной подвыборки не существует: уведомления ей не отправлялись.
- Сравнение «открывших» с контролем сопоставляет активных клиентов со всеми и приписывает различие воздействию.
- Основной анализ ведётся по назначению (intention to treat). Эффект на фактически получивших воздействие оценивается специальными методами.

Поле saw_offer в pilot_outcomes. Истинный эффект известен, поскольку данные синтетические. Прогон 12.10.

ЛЕКЦИЯ 08 / 02

Эффект и доверительный интервал

величина эффекта и её точность

Разность средних и доверительный интервал

```
from statistics import NormalDist

def diff_ci(t, c, alpha=0.05):
    d = t.mean() - c.mean()
    se = (t.var() / len(t)
          + c.var() / len(c)) ** 0.5
    q = NormalDist().inv_cdf(1 - alpha / 2)
    return d, d - q * se, d + q * se

spend = df.groupby("grp")["spend"]
diff_ci(spend.get_group("test_1"),
        spend.get_group("control"))
# (314.5, 161.1, 468.0)
```

	test_1	test_2
эффект, ₽	+315	+19
95 % ДИ	161…468	−127…166
в % к контролю	+9,7 %	+0,6 %
p (Уэлч)	0,00006	0,79

- Стандартная ошибка — по дисперсиям групп раздельно (Уэлч).
- Интервал характеризует величину эффекта, p-значение — лишь отличие от нуля.
- В сводке HypEx интервала нет.

Контроль: 3 256 ₽ на клиента за 4 недели. Нормальное приближение оправдано объёмом групп (около 4 000). Прогон 12.10.

Защитные метрики и выбор критерия по типу метрики

Метрика, test_1	control	test_1	p	
отток	2,66 %	2,68 %	0,96	t
обращений на клиента	0,055	0,082	<0,0001	t
переходы на Расширенный	2,66 %	1,48 %	0,0011	χ^2 x

Число обращений выросло на 49 %: клиенты уточняют, почему повышенный кэшбэк начислен не на все покупки. Доля переходов на Расширенный тариф снизилась — эффект каннибализации.

- Критерий определяется типом метрики: числовая — t-критерий Уэлча; доля (0/1) — тот же t-критерий; категориальная — χ^2 по таблице частот.
- χ^2 в HypEx 1.0.7 работает только на колонке строкового типа и занижает частоты: p = 0,033 вместо 0,0011 (приложение).
- Ухудшились две защитные метрики из трёх. По правилу — доработка и повторный пилот, несмотря на рост оборота.
- В test_2 различий не выявлено: p от 0,22 до 0,64.

Отток — churned, обращения — tickets, переходы — tariff_end; χ^2 — scipy.stats.chi2_contingency. Прогон 12.10.

Статистическая и практическая значимость

На клиента за 4 недели	
комиссия с прироста оборота: 315 × 1,5 %	+4,7
при нижней границе ДИ: 161 × 1,5 %	+2,4
недополученные переходы: −1,18 п. п. × 200 ₽	−2,4
обращения: 0,027 × 150 ₽	−4,1
итого	−1,7

- Оборот вырос на 9,7 % при p = 0,00006, однако с учётом защитных метрик результат отрицателен.
- Статистическая значимость означает лишь, что эффект отличен от нуля. Экономическая целесообразность оценивается отдельно, в денежном выражении.
- Ставка комиссии и стоимость обращения в данных отсутствуют; это допущения, и в отчёте они приводятся рядом с выводом (см. тему 06).

Допущения: комиссия 1,5 % (как на С6); стоимость обращения 150 ₽; переход на Расширенный — 200 ₽ в месяц (разница тарифов). Кэшбэк финансирует партнёр.

Типичные ошибки интерпретации p-значения

1. «При p = 0,03 гипотеза верна с вероятностью 97 %». Неверно: p-значение вычисляется при условии истинности H_0 и не равно $P(H_0 \mid \text{данные})$. Для последней требуется априорное распределение.

2. «Эффект незначим — следовательно, его нет». Неверно: при недостаточной мощности незначимость означает нехватку данных. Утверждать, что эффект меньше X, позволяет доверительный интервал, целиком лежащий ниже X.

3. «При p = 0,00006 эффект велик». Неверно: p-значение зависит от объёма выборки. Величина эффекта характеризуется оценкой и интервалом в единицах метрики.

4. «Проверим дополнительно по сегментам и метрикам». Каждая дополнительная проверка увеличивает вероятность ложного обнаружения; количественно — далее.

Эвристика Тваймана: результат, выглядящий необычным или особенно удачным, чаще всего оказывается ошибочным.

Снижение дисперсии

повышение точности оценки

CUPED: поправка по данным до эксперимента

$$Y_{cuped} = Y - \theta(X - \bar{X}), \theta = \frac{cov(Y, X)}{var(X)}$$

- Y — оборот в окне пилота, X — оборот того же клиента в августе, до назначения.
- Значительная часть межклиентской дисперсии отражает устойчивый уровень трат клиента. Он известен заранее и вычитается.
- При оптимальном θ дисперсия уменьшается в $1 - \rho^2$ раз, где ρ — корреляция Y и X; выигрыш оценивается заранее.

Почему поправка не искажает эффект

X измерен до назначения в группы. Поправка $\theta(X - \bar{X})$ не зависит от группы назначения; её среднее в каждой группе близко к нулю в силу рандомизации. Поэтому эффект сохраняется в среднем.

Условие нарушается, если ковариата подвержена влиянию воздействия.

Deng, Xu, Kohavi, Walker, 2013. Controlled-experiment Using Pre-Experiment Data. Для CUPED достаточно одного предшествующего периода.

CUPAC: ковариата как прогноз модели

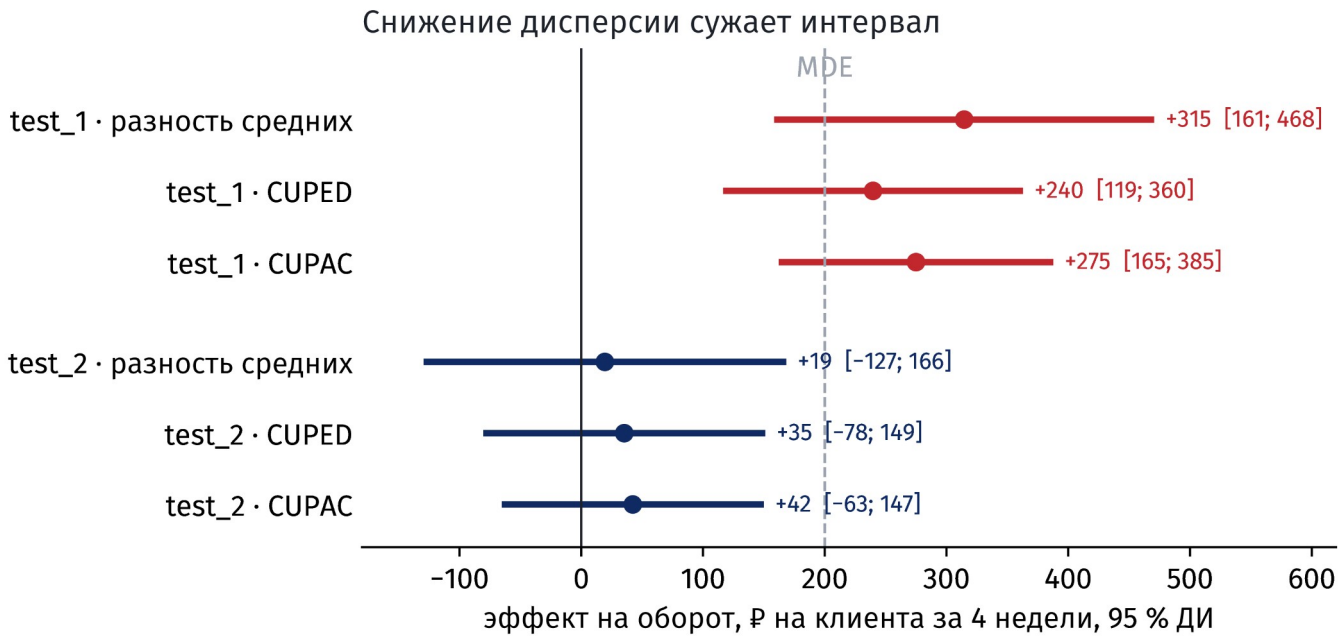


снижение дисперсии, CUPED	39,2 %
CUPAC, кросс-валидация	44,1 %
CUPAC, фактическое	48,1 %

- Модель обучается на переходе июль → август, где воздействия ещё нет.
- Обученная модель применяется к переходу август → сентябрь; её прогноз служит ковариатой.
- spend_prev используется дважды: как целевая переменная при обучении и как признак при применении.
- Число сессий дополняет информацию об активности клиента, содержащуюся в обороте. Выигрыш относительно CUPED — 9 п. п.

Роли: TargetRole(cofounders=["sessions"]), PreTargetRole и FeatureRole с параметрами parent и lag. Лучшая модель — ridge. Прогон 12.10.

Результат снижения дисперсии



- CUPED по августу: θ = 0,658, дисперсия ниже на 39 %. Ширина интервала для test_1 сократилась с 307 до 241 ₽; с CUPAC — до 220, что эквивалентно удвоению выборки.
- Для test_2 верхняя граница интервала — 149 ₽, ниже MDE: эффекты выше 149 ₽ несовместимы с 95 % ДИ при данном методе.
- Оценка test_1 снизилась с 315 до 240 ₽: в августе группа случайно превосходила контроль на 114 ₽.

Интервал CUPAC восстановлен по p-значению сводки HypEx (нормальное приближение). Код CUPED — приложение и C8. Прогон 12.10.

Условия, при которых снижение дисперсии искажает оценку

Ковариата, измеренная после назначения

Вместо августовского оборота использовано число покупок в окне пилота:

ковариата	$\Delta\sigma^2$	test_1	p
оборот, август	−39 %	+240 ₽	0,0001
покупки, сентябрь	−70 %	+38 ₽	0,38

Дисперсия уменьшилась сильнее, но вместе с ней исчезло около 85 % эффекта: кэшбэк влиял на число покупок.

- Ковариату нужно измерять строго до назначения в группы.
- При слабой связи ($\rho < 0{,}3$) снижение дисперсии не превышает 9 % и не оправдывает усложнения анализа.
- При изменении состава аудитории между периодами (приток новых клиентов, сезонность) фактическое снижение дисперсии у CUPAC оказывается ниже оценки по кросс-валидации.

Поправка по purchases из pilot_outcomes — намеренная ошибка для демонстрации. Прогон 12.10.

Множественные проверки

источники ложных обнаружений

Множественные сравнения

$$P(\text{хотя бы одно ложное отвержение}) = 1 - (1 - \alpha)^k$$

Учебный набор: 2 группы × 4 метрики — 8 проверок. При независимости риск хотя бы одного ложного открытия — около 34 %.

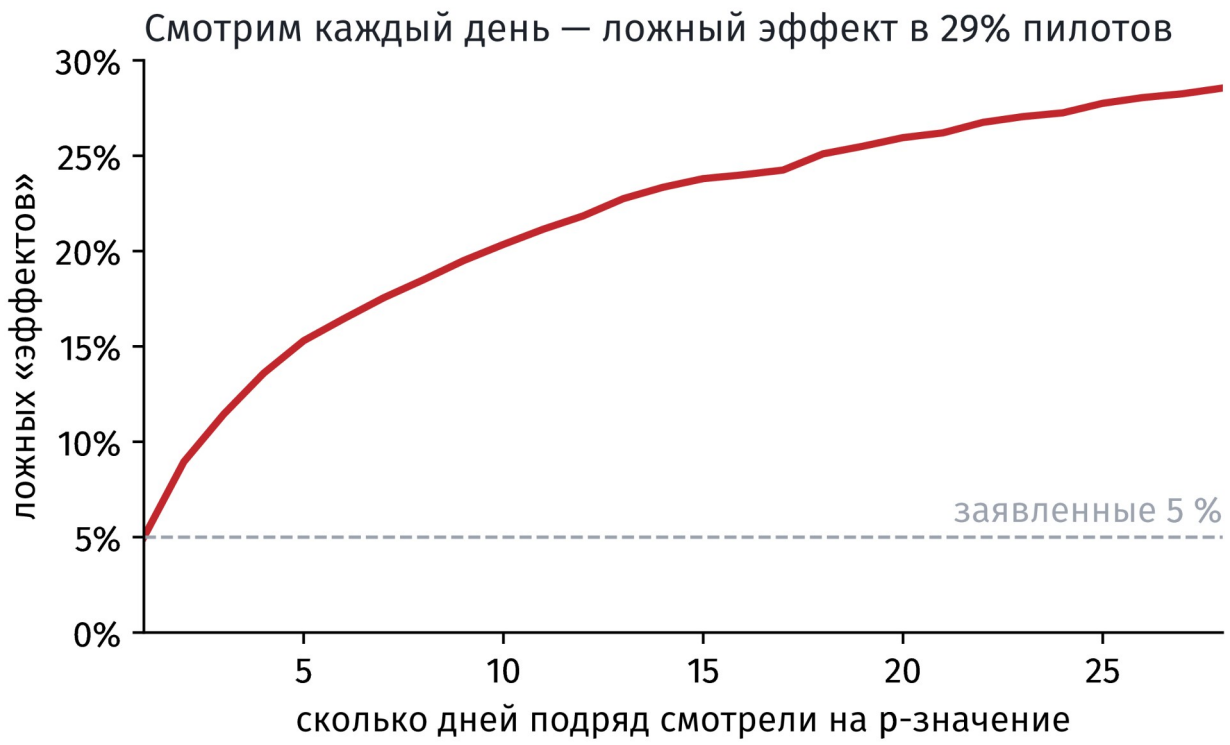
метрика	группа	исходное p	Холм	Бонф.
обращения	test_1	0,000004	0,00003	0,00003
покупки	test_1	0,00003	0,0002	0,0002
оборот	test_1	0,00006	0,0004	0,0005
отток	test_2	0,22	1	1
остальные четыре		0,64…0,96	1	1

from hypex.utils.enums import ABNTestMethodsEnum; res.multitest. Прогон 12.10.

- Метод Холма мощнее поправки Бонферрони при том же контроле групповой ошибки. Процедура Бенджамини—Хохберга контролирует долю ложных среди отвергнутых гипотез — для разведочного анализа.
- Семейство и метод задают до получения результатов; для основной метрики в дизайне заранее указаны 2 сравнения.

В HypEx 1.0.7 метод передаётся членом перечисления ABNTestMethodsEnum. Строка "bonferroni" игнорируется без предупреждения
— применяется метод Холма: 0,00036 вместо
0,00048.

Промежуточные проверки: 29 % ложных обнаружений



- Эффект отсутствует. p-значение вычисляется ежедневно, эксперимент останавливается при первом $p < 0{,}05$.
- Одна проверка в конце окна — 5 % ложных обнаружений; ежедневные проверки в течение недели — 18 %; в течение четырёх недель — 29 %.
- Каждая промежуточная проверка — дополнительное сравнение.
- Досрочная остановка допустима только по плану, заданному до запуска (последовательные методы).

Симуляция: 2 000 экспериментов по 4 000 клиентов на группу, оборот накапливается 28 дней, эффект отсутствует. Прогон 12.10.

Поиск эффекта в сегментах

test_2: 7 каналов и 11 часовых поясов — 18 сравнений

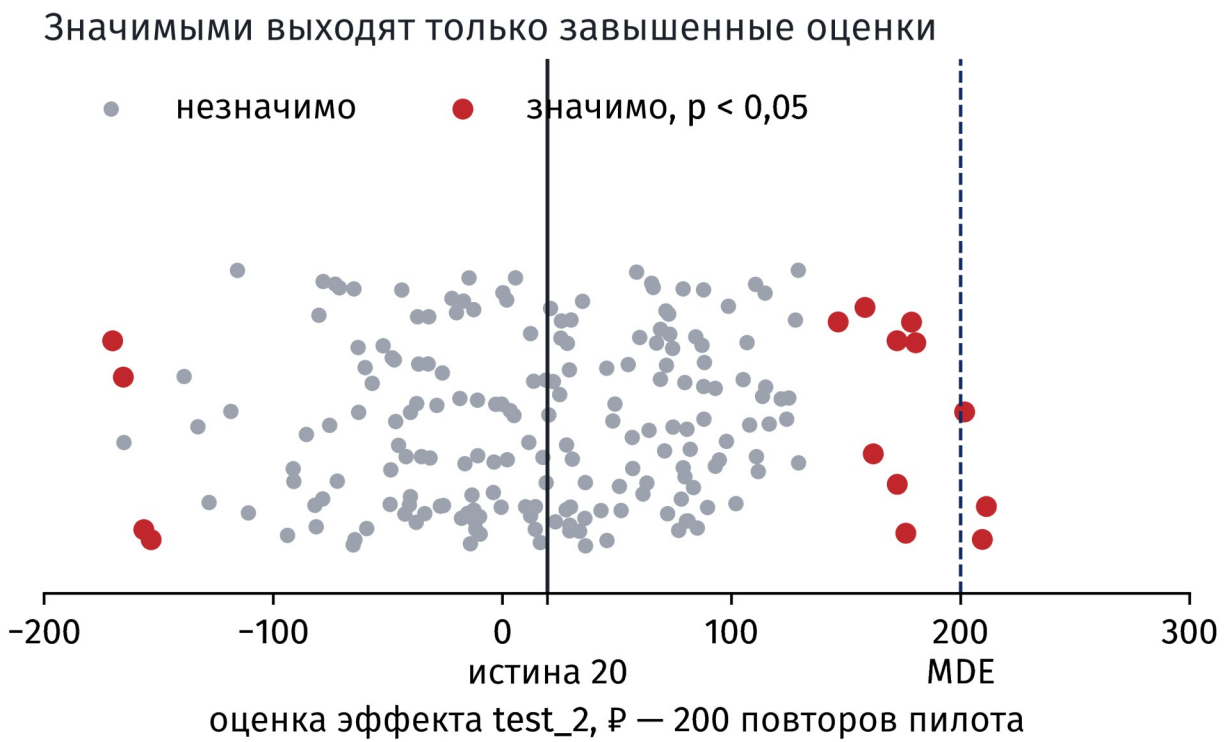
сегмент	клиентов	эффект	p
Asia/Omsk	318	−15 %	0,13
Asia/Krasnoyarsk	492	+12 %	0,21
crm	975	+8 %	0,24
Asia/Yakutsk	148	+24 %	0,25

В данной реализации ни одно сравнение не достигло $p < 0{,}05$.

- При отсутствии эффекта вероятность получить хотя бы один «значимый» сегмент из 18 ≈ 60 % (если независимы); симуляция на наших данных даёт 57 %.
- Оценка «+24 % в Якутске» получена на 148 клиентах; её неопределённость сопоставима с самой оценкой.
- Сегмент, выявленный в данных, — гипотеза для следующего пилота, а не результат текущего.

Симуляция: 500 случайных переразбиений control и test_2 без эффекта, 18 сегментов, минимальное p. Прогон 12.10.

Проклятие победителя



- Пилот повторён 200 раз. Истинный эффект test_2 — 20 ₽, в 10 раз меньше MDE.
- Значимым результат оказался в 15 повторах, из них в 11 — с положительной оценкой, в среднем 179 ₽: в 9 раз выше истинного значения.
- Маломощное сравнение достигает значимости, лишь когда случайная ошибка смещает оценку вверх; значимый результат систематически завышен.

Генератор пилота: те же клиенты, повторное случайное назначение и исходы. Критерий Уэлча, α = 0,05. Прогон 12.10.

Пилот без рандомизации

назначение вне контроля исследователя

Квазиэксперимент: опция, включённая партнёром

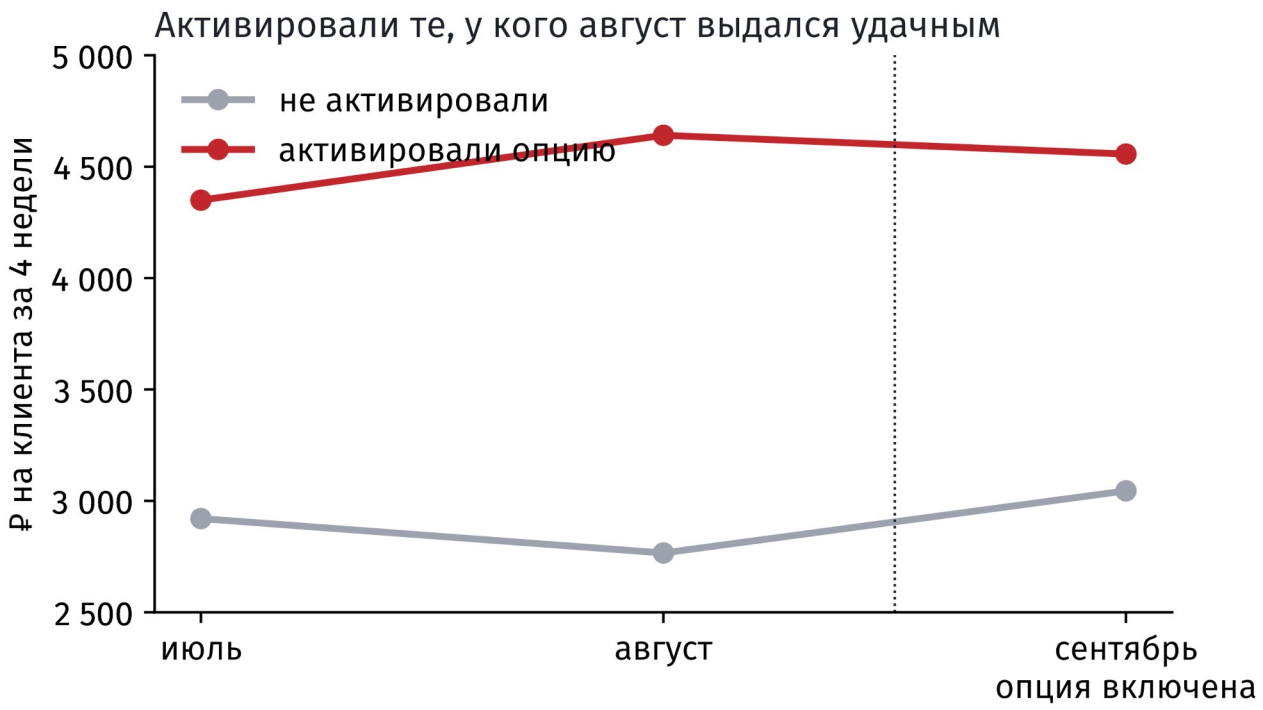
В сентябре партнёр «Мобильный оператор» предложил своим абонентам тот же кэшбэк 5 % на доставку. Опцию активировали в приложении 2 004 из 9 000 абонентов.

	активировали	не активировали
средний возраст	33,1	37,1
оборот в августе	4 641 ₽	2 766 ₽
оборот в сентябре	4 557 ₽	3 045 ₽

prime.rollout_telecom. Истинные значения по генератору: ATT 257 ₽, ATC 183 ₽, ATE 200 ₽. Прогон 12.10.

- Назначение неслучайно: опцию активировали преимущественно более молодые и более активные клиенты. Различие в сентябре — 1 511 ₽, однако и в августе различие составляло 1 875 ₽.
- Повторное назначение невозможно: воздействие уже произошло.
- Это наблюдательное исследование. Далее сравним три метода оценки.

Разность разностей и проверка на предшествующих периодах



Оценка	₽
разность средних	+1 511
«до и после» у активировавших	−84
разность разностей (DiD)	−363
плацебо-DiD: июль → август	+446

- DiD требует параллельных трендов: без воздействия показатели групп изменялись бы одинаково.
- Плацебо-оценка должна быть близка к нулю, а равна +446: опцию активировали клиенты с нетипично высоким августовским оборотом — регрессия к среднему.

Средние по группам за 4 недели. Плацебо: изменение «июль → август» у активировавших минус то же у остальных. Прогон 12.10.

Мэтчинг (подбор сопоставимых наблюдений)

$$\hat{\tau} = \frac{1}{n}\sum_{i=1}^{n} \left(\hat{Y}_i(1) - \hat{Y}_i(0)\right)$$

- Один потенциальный исход наблюдается, второй восстанавливается по ближайшим наблюдениям противоположной группы — «близнецам».
- Близнецы получившим воздействие (из не получивших) дают ATT; не получившим (из получивших) — ATC.
- ATE — разность средних двух дополненных групп;
- Мэтчинг как метод оценки применим к данным А/Б-теста (С8).

Условия корректности оценки

- условная независимость: при заданных признаках назначение не зависит от потенциальных исходов;
- пересечение: для каждого сочетания признаков есть наблюдения обеих групп;
- смещение небольшое: при сильном близнецы далеки, и коррекция его не компенсирует.

Ненаблюдаемые факторы подбором не устраняются, и проверить их отсутствие по данным нельзя.

Abadie, Imbens, 2006. Подбор по расстоянию Махаланобиса, с возвращением, с коррекцией смещения (Abadie, Imbens, 2011).

Мэтчинг в HypEx: роль набора признаков

```
from hypex import Matching
from hypex.dataset import FeatureRole

feats = ["age", "tenure_days", "kyc_level",
         "members", "spend_prev", "sessions_prev"
         ]
ds = Dataset(roles={
        "client_id": InfoRole(str),
        "treated": TreatmentRole(),
        "spend": TargetRole(),
        **{f: FeatureRole() for f in feats}},
    data=roll, default_role=InfoRole())

res = Matching(n_neighbors=5).execute(ds)
res.resume
```

	оценка	95 % ДИ	истина
ATT	264	97…431	257
ATC	197	6…388	183
ATE	212	34…390	200
один близнец: ATT 231, ДИ −17…479			
без spend_prev и sessions_prev: ATE 1 385			

- ATT > ATC: опцию активировали более активные клиенты, у которых абсолютный эффект выше.
- Исключение из признаков августовского оборота, по которому шёл отбор, возвращает оценку почти к наивной разности.

Matching всегда оценивает все три величины; параметра metric в 1.0.7 нет. 9 000 строк — 5,5 с. Прогон 12.10.

Качество подбора по каждому направлению

	0: близнецы не активировавшим		1: близнецы активировавшим	
признак	t	KS	t	KS
age	нет	нет	да	да
tenure_days	да	нет	да	да
kyc_level, members	да	да	да	да
spend_prev	нет	нет	нет	да
sessions_prev	да	нет	нет	да

- res.quality_results: по строке на признак для направлений 0 и 1.
- 2 004 активировавшим близнецы подбираются из 6 996, в обратном направлении — 6 996 из 2 004; средняя разница возраста в паре 1,7 и 2,2 года.
- Поэтому ATC оценивается менее надёжно, чем ATT; это снижает надёжность ATE. Перед использованием ATE проверяется направление 0.

Один близнец; «да» — тест не выявил различий (α = 0,05). Это не доказывает баланс; нужны SMD. Прогон 12.10.

Решение и отчёт

интерпретация и оформление результата

Интерпретация незначимого результата

test_2: уведомление без изменения условий

оценка с CUPED	+35 ₽
95 % ДИ	−78…149 ₽
MDE	200 ₽

Некорректно: «эффекта нет».

Корректно: «эффект не обнаружен; эффект более 149 ₽ данным пилотом исключён».

- Незначимость сама по себе не даёт оснований ни принять H_0, ни заключить, что эффекта нет. Диапазон совместимых с данными эффектов показывает доверительный интервал.
- Если интервал целиком лежит ниже MDE, эффект, ради которого проводился пилот, исключён — это основание для решения.
- Если интервал широк и включает MDE, вопрос остаётся открытым, и вывод «изменение не работает» неправомерен.

Истинный эффект по генератору — 20 ₽: он существует, но в 10 раз меньше MDE, и пилот закономерно его не обнаружил.

Решение: тиражирование, доработка, отказ

Группа	Эффект на оборот	Защитные метрики	Решение
test_1	+240 ₽, ДИ 119…360 (CUPED), значим после поправки Холма	обращения +49 %; переходы на Расширенный −1,2 п. п.	доработать и повторить
test_2	+35 ₽, ДИ −78…149	без изменений	не тиражировать

- Для test_1 условие «эффект значим, защитные метрики без ухудшения» не выполнено. Метрики подсказывают, что доработать: разъяснить условия кэшбэка и сохранить стимул к переходу на Расширенный тариф.
- Продление пилота «до достижения значимости» эквивалентно промежуточным проверкам. Решение о продлении принимается по заранее заданному правилу, а не по текущему p-значению.

Решающее правило — Л7, раздел «Гипотеза».

Отчёт о пилоте

Пилот «Кэшбэк 5 % на доставку», 31.08–27.09.2026

Дизайн, зафиксированный до запуска. Три группы по 4 000 владельцев подписок Базового тарифа, стратификация по каналу привлечения. Основная метрика — оборот за 4 недели, оцениватель CUPED по августу. α = 0,05, мощность 0,8, MDE 200 ₽, поправка Холма. 55 клиентов с повторным назначением исключены; дисбаланса групп не выявлено (p = 0,35).

Результаты. Кэшбэк: +240 ₽ (+7 %), 95 % ДИ 119…360, эффект значим. Уведомление: +35 ₽, ДИ −78…149, эффект незначим.

Защитные метрики. Кэшбэк: обращения +49 %, доля переходов на Расширенный снизилась с 2,7 до 1,5 %. Отток без изменений.

Ограничения. Экономический эффект рассчитан при допущениях (комиссия 1,5 %, стоимость обращения 150 ₽) и при них отрицателен. Эффект уведомления менее 149 ₽ не исключён.

Решение. Кэшбэк — доработать условия и повторить пилот; уведомление — не тиражировать.

- Отчёт рассчитан на читателя, не видевшего ни кода, ни данных.
- Сначала приводится то, что было зафиксировано до запуска.
- Оценки приводятся с интервалами и в единицах метрики.
- Раздел ограничений обязателен: отчёт без него, как правило, утверждает больше, чем позволяют данные.
- Структура согласуется со схемой Л6: что произошло → за счёт чего → чего мы не знаем → что делать.

Итоги лекции

- Оценке эффекта предшествуют проверки: повторы в журнале назначения, соотношение размеров групп, баланс по предпериоду. Отбор по событию после назначения недопустим.
- Эффект приводят с доверительным интервалом и в денежном выражении. Статистическая значимость не означает экономической выгоды. При решении учитывают защитные метрики наравне с основной.
- CUPED по предшествующему периоду сокращает интервал так же, как увеличение выборки. Ковариата измеряется строго до назначения.
- Каждая дополнительная проверка — дополнительное сравнение: поправка на множественность, фиксированное окончание, сегменты как гипотезы для следующих пилотов.
- Значимый результат маломощного сравнения систематически завышен.
- Без рандомизации DiD проверяется плацебо-тестом на предшествующих периодах, мэтчинг — качеством подбора в обоих направлениях. Мэтчинг учитывает небольшие смещения по наблюдаемым признакам — и только их.

Семинар С8: гр. А — ср 11.11, 19:40; гр. Б — сб 14.11, 14:40. ДЗ-3: выдача 14.11, срок сдачи 21.11, 23:59.

Приложение

для самостоятельного чтения

Разность средних в HypEx

```
from hypex import ABTest
from hypex.dataset import (Dataset, InfoRole,
    TargetRole, TreatmentRole)

ds = Dataset(roles={
        "client_id": InfoRole(str),
        "grp": TreatmentRole(),
        "spend": TargetRole()},
    data=df, default_role=InfoRole())

res = ABTest(additional_tests=["t-test", "u-test"]
             ).execute(ds)
res.resume
```

группа	разность	t: p	U: p
test_1	+314,5	0,00006	0,0007
test_2	+19,4	0,79	0,85

- Разность совпадает с ручным расчётом с точностью до копейки.
- Доверительного интервала сводка не содержит; он рассчитывается функцией diff_ci.
- Словарь ролей не следует использовать повторно: Dataset дописывает в него остальные колонки, а создание второго вызывает ошибку RoleColumnError.

HypEx 1.0.7, res.resume сокращено. Прогон 12.10.

Выбор критерия по типу метрики

Метрика (тип)	Критерий
оборот (числовая)	t (Уэлч) — сравнение средних; U — сравнение рангов наблюдений
отток (доля 0/1)	t на 0/1, эквивалентный z-критерию для долей
тариф в конце окна (категориальная)	χ^2 на колонке строкового типа

тариф в конце окна	control	test_1
Расширенный	2,66 %	1,48 %
χ^2 по трём исходам, p	0,0011	

scipy.stats.chi2_contingency по таблице частот, три исхода. Прогон 12.10.

- U-критерий Манна — Уитни — сравнение рангов наблюдений; не является тестом равенства средних. Если выводы расходятся, анализируют распределения, а не выбирают удобный результат.
- χ^2 в HypEx применяется только к колонке строкового типа; для int64 он молча пропускает расчёт.
- В версии 1.0.7 частоты перед расчётом масштабируются на долю другой группы: p = 0,033 вместо 0,0011 по scipy.

Защитные метрики test_1

Метрика	control	test_1	p
отток за окно	2,66 %	2,68 %	0,96
обращений на клиента	0,055	0,082	<0,0001
переходы на Расширенный	2,66 %	1,48 %	0,0011

Число обращений выросло на 49 %: клиенты уточняют, почему повышенный кэшбэк начислен не на все покупки.

- Отток не изменился: интервал −0,7... + 0,7 п. п.
- Ухудшились две защитные метрики из трёх. По правилу это означает доработку и повторный пилот при росте основной метрики.
- В test_2 различий не выявлено: p от 0,22 до 0,64.

Отток — churned, обращения — tickets, переходы — tariff_end. Прогон 12.10.

CUPED в HypEx

```
from hypex.dataset import PreTargetRole

ds = Dataset(roles={
        "client_id": InfoRole(str),
        "grp": TreatmentRole(),
        "spend": TargetRole(),
        "spend_prev": PreTargetRole(parent="spend",
                                    lag=1)},
    data=df[["client_id", "grp", "spend",
             "spend_prev"]],
    default_role=InfoRole())

res = ABTest(cuped_features={"spend": "spend_prev"}
             ).execute(ds)
res.cuped.resume        # variance_reduction 39.2%
```

	test_1	test_2
без поправки	+315	+19
CUPED	+240	+35
ДИ CUPED	119…360	−78…149

- θ = 0,658; дисперсия ниже на 39 %, что совпадает с ρ^2.
- Оценка test_1 изменилась, поскольку в августе группа случайно превосходила контроль на 114 ₽.

Истинные эффекты по генератору: +197 и +20 ₽. CUPED повышает устойчивость оценки в среднем по возможным реализациям, а не точность каждой отдельной оценки. Прогон 12.10.

Мэтчинг на данных А/Б-теста

Тот же пилот: control против test_1

Метод оценки	эффект	95 % ДИ
разность средних	315	161…468
CUPED	240	119…360
мэтчинг, ATE	347	163…531
истинный эффект	197	

- Мэтчинг как метод оценки применим к данным РКИ: он учитывает остаточный дисбаланс после случайного назначения.
- Здесь его оценка согласуется с остальными, но не точнее: сопоставимость групп уже обеспечена рандомизацией, а подбор вносит дополнительную дисперсию.
- В А/Б-тесте обычно используют разность средних или CUPED; мэтчинг уместен при заметном дисбалансе по существенному признаку.

Те же шесть признаков, один близнец. Прогон 12.10.